

Коллектор: очередь риска

Сопроводительное техническое руководство

ЛЦТ 2026 · Кейс 08 · Руководство v2, код c36408e · 29 сентября 2026

Разработан локальный веб-сервис для приоритизации проверки инженерных коллекторов по журналу мониторинга. В сервисе доступны прогнозы для 78 объектов, две разные целевые задачи, выбор сохранённого выпуска, карточка объекта, локальные черновики заявок и журнал решений диспетчера.

Руководство описывает фактически реализованное решение и его ограничения в соответствии с §§14 и 19 оригинального ТЗ. Код находится в приватном репозитории; доступ экспертов ещё не подтверждён; наименование команды и контакты здесь не подменяются вымышленными реквизитами.

Две цели, два разных смысла предупреждения

Цель в интерфейсе	Что прогнозируется	Правило выдачи
Любая тревога	Хотя бы одна тревожная запись на объекте в целевом дне; продолжение серии также считается	Прежняя сохранённая модель и её замороженный порог
Начало серии	День D+1 без тревожных записей, затем тревожная запись в D+2	Отдельная исследовательская модель; ровно 10 объектов ежедневно

Score служит для ранжирования; он не калиброван как вероятность физического отказа. Тревога в журнале не доказывает поломку. Отсутствие записей не доказывает исправность.

Временной контракт объектного прогноза

История доступна по день D включительно. Условный исторический выпуск происходит в D+1 00:00 МСК. Целевое окно: от D+2 00:00 до D+3 00:00 МСК, правая граница исключена. До начала окна остаются ровно 24 часа; события внутри окна находятся на расстоянии от 24 до менее 48 часов от выпуска.

В последнем демонстрационном выпуске используются данные по 28 июня 2026; выпуск датирован 29 июня 00:00, целевой день - 30 июня. Данные 29 и 30 июня не входят в расчёт оценки. Для цели «Начало серии» фактическое состояние D+1 тоже неизвестно при выпуске.

Статус: локальное историческое воспроизведение. Рабочий поток СМВУ не подключён; реальные времена поступления дневных пакетов смоделированы. Отдельный прежний канальный режим не гарантирует минимум 24 часа и не используется для такого заявления.

[Исходный код](#) · [Определения и демонстрация](#)

1. Данные и подготовка

Локально получены 12 файлов: восемь годовых архивов событий, пример CSV и три справочника - каналов, объектов и состояний. Контрольные суммы записаны в `import_manifest.json`. Восемь архивов 2019-2026 содержат 313 546 017 строк событий без заголовков, около 313,5 млн. Последний архив заканчивается июнем 2026: речь о восьми календарных годах, а не восьми полных годах наблюдения.

Год	Строк событий	Год	Строк событий
2019	20 993 328	2023	31 937 125
2020	28 172 398	2024	49 023 883
2021	53 698 948	2025	55 541 797
2022	43 483 149	2026	30 695 389

Обработка

- CSV читается из 7z потоком через `bsdtar`, порциями. Даты разбираются явно; строки без даты или идентификатора канала исключаются. Ошибка распаковки останавливает обработку.
- Тревожный флаг приводится к булеву значению. Для текстовых состояний считаются отдельные признаки неисправности, отсутствия питания и других состояний; числовые и текстовые значения учитываются отдельно.
- Строятся суточные агрегаты каналов в `Parquet`. Старые годы 2019-2024 сохранены отдельно; исторические профили до 2025 использовались в канальных исследованиях. Объектный кандидат не заявляет обучение на всех 313,5 млн строках.
- Каналы связываются с объектами по справочнику. Основной объектный эксперимент использует календарь с 1 января 2025 для 78 объектов. Отдельный перенос 2023/2024 использует 74 объекта, выбранных только по истории 2023. Дни без записей имеют отдельный признак наблюдаемости.
- На объекте рассчитываются количества событий и наблюдавшихся каналов, лаги, окна 3/7/28 дней, доли, длины серий, давность тревоги и календарь. `Onset`-кандидат добавляет частоты начал/завершений и шаблон трёх последних дней: всего 80 признаков.

Качество и границы данных

Справочник не восстановлен на каждую историческую дату. При объектной проверке до 30 июня 2026 исключены 163 канал-дня неизвестных каналов, включая 74 с тревогой. Полные итоги покрытия и хеши сохранены в отчётах; объединение использует проверку уникальности ключей.

Подтверждённых меток физической поломки, выполненного ремонта и ложности тревог в переданном наборе нет. Дневное отсутствие записи может означать молчание канала или пробел регистрации. Отдельно загруженная погода является исследовательским контекстом Москвы, а не точными измерениями каждого объекта; в публикуемую `onset`-очередь она не включена.

[Инвентаризация](#) · [Подготовка суточных данных](#)

2. Метод и временная проверка

Выбор модели начала серии

Положительная метка равна 1, если в D+1 нет зарегистрированной тревоги, а в D+2 она есть. Проверены прямой бинарный LightGBM, двухэтапная модель, совместная модель четырёх состояний двух будущих дней, логистическая модель и сглаженная частота начал. Для деревьев заданы два размера: 7 и 15 листьев. После восьми кандидатов проверены три заранее заданные смеси лучшего древесного и статистического вариантов.

Выбран hurdle_15: произведение оценки P(нет тревоги D+1 | история по D) и оценки P(тревога D+2 | нет тревоги D+1, история по D). Второй компонент обучается на соответствующих обучающих строках. При inference оба компонента получают только историю: фактическое состояние D+1 не передаётся. Сохранены 188 и 187 деревьев LightGBM, seed 84.

Этап	Дни признаков	Последний используемый исход
Первичное обучение	01.01-28.09.2025	30.09.2025
Выбор кандидата и числа деревьев	01.10-28.11.2025	30.11.2025
Дообучение выбранных весов	01.01-28.11.2025	30.11.2025
Декабрьская проверка допуска	01-29.12.2025	31.12.2025
Сравнительная диагностика	31.12.2025-28.06.2026	30.06.2026

Критерий выбора: Precision при 10 объектах в день, затем AP и имя кандидата для разрешения равенства. Декабрь не меняет настройки; кандидат должен быть не хуже сопоставимого контроля. Исторический выпуск этого кандидата разрешён с 1 января 2026, после завершения декабрьских исходов. Фактическое создание модели произошло в сентябре 2026; прежняя дата означает лишь границу ретроспективного расчёта.

Проверены также другие семейства

Семейство	Реально выполнено и установлено
Бустинги	CatBoost/LightGBM, ансамбли и месячные обновления в отдельной канальной задаче; LightGBM в объектной
Статистика	Двухшаговые марковские переходы, сезонные частоты, логистическая и сплайновая авторегрессии
Нейросеть	GRU с окнами 28/56 дней; AP на периоде выбора 0,5753/0,5704 против 0,6266 у LightGBM
Смеси	На любой тревоге 75% LightGBM + 25% сезонной статистики; существенного выигрыша при бюджете 10 не получено

Chronos-2, FIM-PP и survival/renewal изучены, но здесь не обучались. Период 2026 ранее исследовался: новая слепая проверка не заявляется.

[Зафиксированный протокол](#) · [Сравнение семейств](#)

3. Качество: одинаковые цели и бюджеты

Сопоставимое сравнение включает 78 объектов, 180 дней выдачи, 14 040 объект-дней. В целевых днях зарегистрированы 2 000 начал серий и 4 203 дня с любой тревогой. Оба ранжирования выбирают ровно 10 объектов ежедневно: по 1 800 предупреждений. Контроль здесь дообучен до ноября 2025; он отличается от прежней пороговой модели интерфейса.

Показатель при 1 800 предупреждениях	Refit-контроль: любая тревога	Кандидат: начало серии
Охвачено начал	316	435
Precision по началам	17,56%	24,17%
Recall по началам	15,80%	21,75%
AP по началам	0,1957	0,2406
Повторные тревожные дни в выдаче	976	333
Дни без тревоги в выдаче	508	1 032
Precision по любой тревоге	71,78%	42,67%
Recall по любой тревоге	30,74%	18,27%

Чистый прирост: 119 начал, или 37,7% относительно 316. Precision по началам вырос на 6,61 процентного пункта. Парный bootstrap по неделям выдачи: 1 000 повторов, 27 недель; 95% интервал прироста 5,22-8,14 п.п. Интервал описывает вариацию известного периода, не устраняя повторное использование 2026 или зависимость между неделями. В декабре: 67 против 49 начал при 290 предупреждениях.

Наблюдаемость и цена изменения цели

Записи на промежуточном D+1	Начал всего	Контроль: охвачено	Кандидат: охвачено
Нет любых записей	726	35	110
Есть хотя бы одна запись	1 274	281	325

Из чистого прироста 119 охваченных начал 75 приходится на дни после отсутствия любых записей (110 - 35). Возможное объяснение - возобновление регистрации. В наблюдаемой страте прирост составляет 44. Будущая наблюдаемость не фильтрует выдачу; группы используются только для анализа. Рост поиска начал сопровождается увеличением дней без любой тревоги среди предупреждений. Кандидат не заменяет прежнюю цель автоматически.

Отдельный прежний результат, другой бюджет

Старая замороженная модель любой тревоги, обученная до сентября с выбором на октябрь-ноябрь, при пороге 0,334523 дала 4 400 предупреждений: 2 504 верных, 1 896 ложных. Precision 56,91%, Recall 59,58%, AP 0,6213. Такие показатели нельзя смешивать с 316 началами и Precision 71,78% у дообученного контроля при 1 800 предупреждениях. Начало серии и любая тревога также имеют разные знаменатели Recall.

[Полный onset-отчёт](#) · [Старая модель и порог](#)

4. Перенос метода на 2024 год

Метод проверен на другом историческом периоде без перенастройки по 2024. Популяция включает 74 объекта с записями до 28 сентября 2023. Оценка охватывает 181 день выдачи и 13 394 объект-дня. Всего 1 725 начал зарегистрированной серии; каждая очередь содержит 1 810 предупреждений, по 10 ежедневно.

Метод	Охвачено начал	Precision@10	Без любой тревоги
Контроль любой тревоги	293	16,19%	547
Историческая частота начал	358	19,78%	1 027
Двухэтапная модель	414	22,87%	1 067

Выигрыш относительно исторической частоты составляет 56 начал, или 15,6%, при том же числе предупреждений. Относительно контроля любой тревоги прирост равен 121, или 41,3%. При этом предупреждений без тревоги стало больше: на 40 против частоты и на 520 против контроля. Модель не объявляется универсально лучшей для любой цели.

Разделение по времени

Обучение использует признаки до 28.09.2023 и исходы до 30.09.2023. Октябрь-ноябрь определяют число деревьев, затем веса дообучаются до 28.11.2023. Декабрьская проверка не меняет настройки: 68 начал против 49 при 290 предупреждениях. Выдачи для оценки идут с 01.01 по 29.06.2024, целевые дни - с 02.01 по 30.06.2024. Рабочие веса интерфейса по результатам этого переноса не заменялись.

Наблюдаемость и пределы вывода

Из чистого прироста 121 попадания против контроля 93 приходится на дни после D+1 без любых записей: 135 против 42. Однако против частоты в этой страте модель проигрывает 25 попаданий (135 против 160), а при наличии записей выигрывает 81 (279 против 198). Весь выигрыш над частотой нельзя объяснить только возобновлением регистрации. Будущая наблюдаемость используется исключительно для анализа результатов.

Проверка ретроспективная. Семейство выбрано по более поздним исследованиям, справочник текущий, фактическое время поступления записей неизвестно. Отсутствие настройки по 2024 не делает этот период новым слепым испытанием и не доказывает прогноз физических поломок.

Независимо пересчитаны 80 961 008 исходных строк 2023/2024. Все ключи и 11 используемых счётчиков совпали с дневными кэшами. Такая сверка не восстанавливает утраченную версию старого агрегатора и не проверяет неиспользуемые числовые агрегаты. Отдельные 119 проверок подтвердили метрики, временные границы и воспроизведение сохранённых оценок.

[Протокол и результаты переноса](#) · [Независимая проверка](#)

5. Архитектура и интерфейсы

От суточного пакета до решения диспетчера

1. Подготовка: 7z/CSV и справочники преобразуются в суточные Parquet вне API.
2. Producer: object_forecast.py и object_onset_forecast.py собирают доступную историю и рассчитывают сохранённые модели соответствующих целей.
3. Архив: forecast_store.py проверяет и сохраняет неизменяемый выпуск в SQLite: карточки, цель, политика, даты, хеши входа/модели/кода и версия.
4. FastAPI и браузер показывают выбранный выпуск, ранг, наблюдаемость и историю. Схема групп воспроизводит справочник, не географию.
5. Карточка получает рекомендации по доступным фактам: полнота записей, текущие и повторные тревоги. Сервер сохраняет рекомендацию и версию правил вместе с решением или черновиком. Клиентский текст рекомендации не подменяет серверный снимок. Ремонт определяется диспетчером; внешней отправки нет.

Защита от будущих данных и подмены версии

Пакет принимается после окончания дня и не позже условного выпуска. Поздние данные не меняют прошлые выпуски. Отсутствующий пакет не считается подтверждённым пустым днём. Проверяются ключи, счётчики, схема и контрольные суммы.

Семь будущих и целевых полей удаляются до inference. На двух датах 78 оценок воспроизведены точно, добавление будущих дней их не меняет. Onset сохраняет ID, ранг и выбор ровно десяти объектов, включая равные оценки.

API	Назначение
GET /api/health	Доступность архивных режимов
GET /api/forecast-runs?mode=object	Метаданные сохранённых выпусков
GET /api/risks?mode=object&run_id=...	Карточки выбранного выпуска
GET /api/risks/{id}?mode=object&run_id=...	Одна карточка с проверкой версии
POST /api/tickets	Локальный черновик: risk_id, entity_mode, run_id, note
POST /api/feedback	Решение: те же ключи, operator, decision, reason, note
GET /api/journal?mode=object	Последние решения и черновики со снимками

Маршруты описаны в /docs. Новые выпуски не содержат будущих исходов: outcome возвращает 404. Старый архивный факт раскрывается отдельным действием.

Архив проверяет JSON, схему и SHA-256. Повтор выпуска идемпотентен, конфликт отклоняется; триггеры запрещают обычный UPDATE/DELETE. Копирование использует SQLite online backup, восстановление допускается в новый путь. Явно запускаемый backup_scheduler.py создаёт периодические копии с атомарным статусом и блокировкой второго исполнителя. Автозапуск службы, внешнее хранилище и HA не реализованы. Хеши не защищают от владельца компьютера.

[Архив и контракт](#) · [Автоматические копии и восстановление](#) · [Правила рекомендаций](#)

6. Локальная установка и проверка

Проверен локальный комплект v3: collector-risk-review-v3.zip, 4 491 996 байт, исходный чистый коммит 764d31a. Он содержит код, дневные агрегаты, справочники, две модели и шесть выпусков без пользовательских решений. ZIP остаётся локальным, поскольку включает предоставленные данные и веса. Репозиторий и презентация обновлены отдельно до c36408e.

Распакуйте ZIP в новую папку; команды выполняйте в collector-risk-review. Нужен Python 3.12. API использует FastAPI/Pydantic/Uvicorn; версии зафиксированы в requirements-файлах. OpenMP требуется только для пересчёта LightGBM (на проверенной macOS - Homebrew libomp).

```
python3.12 -m venv .venv
.venv/bin/python -m pip install -r requirements-runtime.txt
.venv/bin/python verify_bundle.py
.venv/bin/python start_demo.py --port 8765
```

Откройте <http://127.0.0.1:8765/>, выберите «Объекты», цель и выпуск. Фильтры меняют видимость, не сохранённую очередь. Seed копируется в отдельную рабочую SQLite; последующие запуски сохраняют журнал. Для проверки используйте явно тестовые имя и комментарий. Корпоративный вход и внешняя отправка не подключены.

Для пересчёта обеих моделей в отдельные базы:

```
.venv/bin/python -m pip install -r requirements-inference.txt
.venv/bin/python src/serving/object_onset_forecast.py \
  --database data/app/recomputed_onset.sqlite3
.venv/bin/python src/serving/object_forecast.py \
  --database data/app/recomputed_any.sqlite3
```

После первого запуска UI периодические копии включаются отдельным процессом:

```
.venv/bin/python scripts/backup_scheduler.py \
  --source data/app/dispatch.sqlite3 --output-dir backups \
  --interval 3600 --timeout 60
```

Границы подтверждённых проверок

V3 прошёл 170 приёмочных утверждений: три автоматические копии, восстановление в новый файл и отдельный HTTP-процесс. Журнал с тестовыми решением/черновиком и двумя рекомендациями, шесть выпусков и 468 карточек совпали. Использовано ранее проверенное чистое Python 3.12.14 окружение без переустановки. В v1 пересчитаны 468 оценок с точным совпадением; v3 сохраняет те же входы, модели и inference-код, но пересчёт в v3 не повторялся.

Полный репозиторий отдельно прошёл 170 Python-тестов и семь сценариев UI. Сопоставимая нагрузка: 19 200 GET/POST, 0 ошибок. При 20 клиентах среднее p95 двух повторов до/после: чтение 311/117 мс, смешанный сценарий 757/376 мс. Медиана выросла. Серии короткие, на одной macOS-машине; требование «без деградации» относительно одного клиента не подтверждено. Нагрузка не включает ML inference; Linux, Windows и промышленный SLA не проверены.

[Комплект и восстановление](#) · [Условия нагрузки](#)

7. Ограничения и материалы проверки

Реализованное и оставшиеся требования

Область	Подтверждено сейчас	Что требуется дальше
Цель прогноза	Регистрация любой тревоги или начала серии	Подтверждённые инциденты, ложность сработок и ремонты
Горизонт	Объектное окно начинается через 24 часа	Реальные времена поступления и контроль задержек
Политика	Ежедневная очередь из 10; повторы допустимы	Проверка нагрузки бригад и отдельная оценка подавления повторов
Интеграции	Локальный API и сохранённые выпуски	Поток СМБУ, корпоративная система заявок
Безопасность	Проверки входов, версии, локальная БД	TLS, роли, LDAP/AD, аудит подтверждённой идентичности
География	Схема групп из справочника	Проверенные координаты и пространственная карта
Эксплуатация	Периодические копии и восстановленный HTTP проверены	Системный автозапуск, внешнее хранилище, HA
Валидация	Временное разделение, причинные тесты, аудит	Новый неиспользованный период и согласованный пилот

ТЗ требует обосновать Precision и Recall по качеству данных, не устанавливая пороги 70%/50%. Наши метрики не доказывают прогноз физических аварий, экономию или промышленную готовность.

Где проверить каждое существенное утверждение

- [ТЗ и уточнённые требования](#): смысл метрик, минимум 24 часа, разрешённое метеобогащение.
- [Инвентаризация данных](#): восемь архивов и размеры; [проверки качества](#): 313 546 017 строк.
- [Протокол и результаты onset](#): 435/316, одинаковые бюджеты, наблюдаемость, интервалы.
- [Независимая проверка](#): 37 проверок, 78 оценок, отсутствие будущих входов, ранги и ID.
- [Python-тесты](#) и [семь сценариев UI](#): границы подтверждённого тестирования.
- [Порядок показа](#), [матрица готовности](#) и [обзоры первичных методов](#): навигация по демонстрации, пробелам и альтернативам.

Ссылки с c36408e фиксируют опубликованную версию кода и отчётов. Частные данные, локальные модели, базы и построчные прогнозы отсутствуют в репозитории Git. Доступ к ним для проверки организуется отдельно в пределах разрешённого использования материалов.

Презентация v4 проверена, но сведения команды не заполнены. Доступ экспертов, внешний прототип и конкурсная сдача не подтверждены. Далее нужен пилот с новыми исходами осмотров и согласованной политикой действий.